

# Les expressions rationnelles et les langages rationnels

## Les langages rationnels

On appelle ensemble des langages rationnels sur  $\Sigma$  et on note  $Rat(\Sigma^*)$  le plus petit ensemble contenant  $\emptyset$ ,  $\{a\}$ ,  $\forall a \in \Sigma$  et fermé pour l'union, le produit de concaténation et l'étoile.

**exemple :**

Soit  $L = \{w \in \Sigma^* \text{ tq } |w|_a \bmod 2 = 0\} = (\{b\}^* \cdot \{a\} \cdot \{b\}^* \cdot \{a\})^* \cdot \{b\}^* \in Rat(\Sigma^*)$ .

On rappelle que  $\emptyset^* = \{\varepsilon\}$ .

**Théorème de Kleene :**

$$Rec(\Sigma^*) = Rat(\Sigma^*)$$

## Les expressions rationnelles

- $\emptyset$  est une expression rationnelle qui désigne le langage rationnel  $\emptyset$
- $\varepsilon$  est une expression rationnelle qui désigne le langage rationnel  $\{\varepsilon\}$
- $a \in \Sigma$  est une expression rationnelle qui désigne le langage rationnel  $\{a\}$

si  $r$  et  $s$  sont deux expressions rationnelles qui désignent respectivement les langages rationnels  $R$  et  $S$ , alors

- $(r + s)$  est une expression rationnelle qui désigne le langage rationnel  $R + S$
- $(r.s)$  est une expression rationnelle qui désigne le langage rationnel  $R.S$
- $(r^*)$  est une expression rationnelle qui désigne le langage rationnel  $R^*$

**remarque :** il ne faut pas confondre  $\varepsilon$  expression rationnelle qui désigne le langage  $\{\varepsilon\}$  et  $\varepsilon$  le mot vide.

Une expression rationnelle désigne exactement un langage rationnel et un langage rationnel est désigné par au moins une expression rationnelle.

**exemple :**  $(a^* + b^*)^*$ ,  $(a^* \cdot b^*)^*$  et  $(a + b)^*$  désignent le même langage rationnel  $\Sigma^*$ .

La démonstration du théorème de Kleene repose sur deux algorithmes ; l'un permet de passer d'une expression rationnelle à un automate et le deuxième d'un automate à une expression rationnelle.

# Construction d'un automate à partir d'une expression rationnelle

Nous présentons ici le détail d'une méthode de construction : l'algorithme de Glushkov.

## L'algorithme de Glushkov

L'algorithme de Glushkov prend en entrée une expression rationnelle et retourne un automate de Glushkov.

Soit  $E$  une expression rationnelle sur l'alphabet  $\Sigma$  et  $L(E)$  le langage désigné par cette expression. On numérote chaque lettre de  $E$  de la gauche vers la droite en commençant à 1. Chaque numéro de lettre est appelé position de cette lettre dans  $E$  et on note  $Pos(E)$  l'ensemble des positions des lettres de  $E$ . Soit  $\overline{E}$  la nouvelle expression ainsi indicée et  $L(\overline{E})$  le langage désigné par cette expression. Notons  $a_i$  la lettre qui apparaît en position  $i$  dans  $\overline{E}$ . Chaque mot  $w$  de  $L(\overline{E})$  commence par une lettre  $a_i$ . La position  $i$  est appelée position initiale de  $w$ . De la même manière, chaque mot  $w$  de  $L(\overline{E})$  se termine par une lettre  $a_j$ . La position  $j$  est appelée position finale de  $w$ .

**Exemple 2 :** soit  $E = (a \cdot b^* + a) \cdot b$ .

L'expression indicée correspondante est  $\overline{E} = (a_1 \cdot b_2^* + a_3) \cdot b_4$

$Pos(E) = \{1, 2, 3, 4\}$ .

On définit les fonctions suivantes :

- $First(E)$  est l'ensemble des positions initiales des mots de  $L(\overline{E})$ .
- $Last(E)$  est l'ensemble des positions finales des mots de  $L(\overline{E})$ .
- $Follow(E, i)$  est l'ensemble des positions des lettres qui suivent  $a_i$  dans les mots de  $L(\overline{E})$ .
- $Null(E) = \varepsilon$  si  $\varepsilon$  est dans  $L(E)$  et  $\emptyset$  sinon.

**Exemple 3 :**

- $\overline{E} = (a_1 \cdot b_2^* + a_3) \cdot b_4$
- $First(E) = \{1, 3\}$
- $Last(E) = \{4\}$
- $Null(E) = \emptyset$
- $Follow(E, 1) = \{2, 4\}$ ,  $Follow(E, 2) = \{2, 4\}$ ,  $Follow(E, 3) = \{4\}$ ,  $Follow(E, 4) = \emptyset$ .

## Calcul des fonctions et des ensembles de positions

rappels :

$\emptyset \cdot E = E \cdot \emptyset = \emptyset$ ,  $\forall E$  une expression rationnelle

$\emptyset^* = \varepsilon$

La fonction  $Null$

$$\begin{aligned}
Null(\emptyset) &= \emptyset \\
Null(\varepsilon) &= \{\varepsilon\} \\
Null(a) &= \emptyset \\
Null(F + G) &= Null(F) \cup Null(G) \\
Null(F \cdot G) &= Null(F) \cap Null(G) \\
Null(F^*) &= \{\varepsilon\}
\end{aligned}$$

La fonction *First*

$$\begin{aligned}
First(\emptyset) &= \emptyset \\
First(\varepsilon) &= \emptyset \\
First(a) &= \{x\} && \text{si } \bar{a} = \alpha_x \\
First(F + G) &= First(F) \cup First(G) \\
First(F \cdot G) &= First(F) \cup Null(F) \cdot First(G) \\
First(F^*) &= First(F)
\end{aligned}$$

La fonction *Last*


$$\begin{aligned}
Last(\emptyset) &= \emptyset \\
Last(\varepsilon) &= \emptyset \\
Last(a) &= \{x\} && \text{si } \bar{a} = \alpha_x \\
Last(F + G) &= Last(F) \cup Last(G) \\
Last(F \cdot G) &= Last(G) \cup Null(G) \cdot Last(F) \\
Last(F^*) &= Last(F)
\end{aligned}$$

La fonction *Follow*

$$\begin{aligned}
Follow(\emptyset, x) &= \emptyset \\
Follow(\varepsilon, x) &= \emptyset \\
Follow(a, x) &= \emptyset \\
Follow(F + G, x) &= \mathcal{I}_{Pos(F)}(x) \cdot Follow(F, x) \cup \mathcal{I}_{Pos(G)}(x) \cdot Follow(G, x) \\
Follow(F \cdot G, x) &= \mathcal{I}_{Pos(F)}(x) \cdot Follow(F, x) \\
&\quad \cup \mathcal{I}_{Pos(G)}(x) \cdot Follow(G, x) \\
&\quad \cup \mathcal{I}_{Last(F)}(x) \cdot First(G) \\
Follow(F^*, x) &= Follow(F, x) \cup \mathcal{I}_{Last(F)}(x) \cdot First(F)
\end{aligned}$$

Ces fonctions permettent de définir l'automate  $\overline{M}$  qui reconnaît le langage  $L(\overline{E})$ . On a  $\overline{M} = (\Sigma, Q, \{i\}, F, \delta)$

1.  $Q = Pos(E) \cup \{i\}$
2.  $\forall x \in First(E), \delta(i, \alpha_x) = \{x\}$
3.  $\forall x \in Pos(E), \forall y \in Follow(E, x), \delta(x, \alpha_y) = \{y\}$
4.  $F = Last(E) \cup Null(E) \cdot \{i\}$



On obtient  $M$  à partir de  $\overline{M}$  en enlevant les indices des lettres de l'alphabet.

# Construction d'une expression rationnelle associée à un automate : algorithme de Mac Naughton et Yamada

Soit  $M = (\Sigma, Q, I, F, \delta)$  un automate avec  $Q = \{1, 2, \dots, n\}$ .

On pose

$R_{ij} = \{w \in \Sigma^* \text{ tq } w \text{ est la trace d'un chemin quelconque de l'état } i \text{ à l'état } j \text{ dans } M\}$

$R_{ij}^k = \{w \in R_{ij} \text{ tq les chemins de } i \text{ à } j \text{ d'étiquette } w \text{ passent par des états intermédiaires inférieurs ou égaux à } k\}$

Considérons un chemin de  $i$  à  $j$  dont la trace est dans  $R_{ij}^k$ .

- Soit ce chemin ne passe pas par  $k$ . Comme les états intermédiaires doivent être inférieurs ou égaux à  $k$ , dans ce cas, ils sont strictement inférieurs à  $k$  et donc inférieurs ou égaux à  $k-1$  et leurs traces sont dans  $R_{ij}^{k-1}$ .
- Soit ce chemin passe par l'état  $k$  (éventuellement plusieurs fois).

Ce chemin peut être décomposé de la manière suivante :

$$i \longrightarrow k \longrightarrow k \longrightarrow k \dots \longrightarrow k \longrightarrow j$$

en mettant en évidence chaque occurrence de  $k$  sur le chemin de  $i$  à  $j$ .

Tous les chemins de  $i$  à  $k$ , de  $k$  à  $k$  et de  $k$  à  $j$  passent par des états intermédiaires inférieurs strictement à  $k$  et donc inférieurs ou égaux à  $k-1$ . Leurs traces sont donc respectivement dans  $R_{ik}^{k-1}$ ,  $R_{kk}^{k-1}$  et  $R_{kj}^{k-1}$ .

On a donc une décomposition de  $R_{ij}^k$  en :

$$R_{ij}^k = R_{ij}^{k-1} \cup R_{ik}^{k-1} \cdot (R_{kk}^{k-1})^* \cdot R_{kj}^{k-1} \text{ pour } k > 0$$

Il faut maintenant définir  $R_{ij}^0$ . Ce sont les traces des chemins allant de  $i$  à  $j$  en passant par des états intermédiaires inférieurs ou égaux à 0. Mais on a posé  $Q = \{1, 2, \dots, n\}$  et il n'existe par conséquent aucun état inférieur ou égal à 0 dans  $Q$ . Cela signifie que ces chemins ne peuvent pas avoir d'état intermédiaire. Ce sont donc des flèches et  $R_{ij}^0$  est l'ensemble des étiquettes de ces flèches :

$$R_{ij}^0 = \{a \in \Sigma \mid j \in \delta(i, a)\}$$

On peut maintenant revenir à  $R_{ij}$ . C'est l'ensemble des traces des chemins allant de  $i$  à  $j$  sans condition sur les états intermédiaires ni sur la longueur. Autrement dit, on peut passer par n'importe quel état intermédiaire c'est à dire par n'importe quel état inférieur ou égal à  $n$  et on peut donc écrire  $R_{ij} = R_{ij}^n$

On peut alors définir le langage reconnu par l'automate par :

$$R = \begin{cases} \bigcup_{i \in I, t \in F} R_{it} & \text{si } I \cap F = \emptyset \\ \bigcup_{i \in I, t \in F} R_{it} \cup \{\varepsilon\} & \text{sinon} \end{cases}$$

En résumé, on a donc les formules suivantes pour les langages :


$$\begin{aligned}
R &= \begin{cases} \bigcup_{i \in I, t \in F} R_{it} & \text{si } I \cap F = \emptyset \\ \bigcup_{i \in I, t \in F} R_{it} \cup \{\varepsilon\} & \text{sinon} \end{cases} \\
R_{ij} &= R_{ij}^n \\
R_{ij}^k &= R_{ij}^{k-1} \cup R_{ik}^{k-1} \cdot (R_{kk}^{k-1})^* \cdot R_{kj}^{k-1} & \forall k > 0 \\
R_{ij}^0 &= \{a \in \Sigma \mid j \in \delta(i, a)\} & \forall i, j \in Q
\end{aligned}$$

On obtient alors les formules suivantes pour les expressions rationnelles qui désignent les langages ci-dessus :

$$\begin{aligned}
r &= \begin{cases} \sum_{i \in I, t \in T} r_{it} & \text{si } I \cap F = \emptyset \\ \sum_{i \in I, t \in T} r_{it} + \varepsilon & \text{sinon} \end{cases} \\
r_{ij} &= r_{ij}^n, & \forall i, j \in Q \\
r_{ij}^k &= r_{ij}^{k-1} + r_{ik}^{k-1} \cdot (r_{kk}^{k-1})^* \cdot r_{kj}^{k-1} & \forall k > 0 \\
r_{ij}^0 &= \sum_{a \in \Sigma, j \in \delta(i, a)} a, & \forall i, j \in Q
\end{aligned}$$

**Exemple :**

On considère l'automate :



L'expression rationnelle obtenue à partir de cet automate par l'algorithme de McNaughton et Yamada est donnée par les formules :

$$r = r_{11} + r_{31} + \varepsilon = r_{11}^3 + r_{31}^3 + \varepsilon$$

Pour calculer ces expressions, il est nécessaire de calculer les  $r_{ij}^k$  pour  $k = 0, 1, 2, 3$ . Nous allons mettre ces calculs dans une table appelée table de McNaughton et Yamada :

$r_{ij}$	$k = 0$	$k = 1$	$k = 1$	$k = 2$	$k = 2$	$k = 3$
$r_{11}$		$r_{11}^0 + r_{11}^0 \cdot (r_{11}^0)^* \cdot r_{11}^0$		$r_{11}^1 + r_{11}^1 \cdot (r_{11}^1)^* \cdot r_{11}^1$		$r_{11}^2 + r_{11}^2 \cdot (r_{11}^2)^* \cdot r_{11}^2$
$r_{12}$		$r_{12}^0 + r_{11}^0 \cdot (r_{11}^0)^* \cdot r_{12}^0$		$r_{12}^1 + r_{11}^1 \cdot (r_{11}^1)^* \cdot r_{12}^1$		$r_{12}^2 + r_{11}^2 \cdot (r_{11}^2)^* \cdot r_{12}^2$
$r_{13}$		$r_{13}^0 + r_{11}^0 \cdot (r_{11}^0)^* \cdot r_{13}^0$		$r_{13}^1 + r_{11}^1 \cdot (r_{11}^1)^* \cdot r_{13}^1$		$r_{13}^2 + r_{11}^2 \cdot (r_{11}^2)^* \cdot r_{13}^2$
$r_{21}$		$r_{21}^0 + r_{21}^0 \cdot (r_{11}^0)^* \cdot r_{11}^0$		$r_{21}^1 + r_{22}^1 \cdot (r_{22}^1)^* \cdot r_{21}^1$		$r_{21}^2 + r_{23}^2 \cdot (r_{33}^2)^* \cdot r_{21}^2$
$r_{22}$		$r_{22}^0 + r_{21}^0 \cdot (r_{11}^0)^* \cdot r_{12}^0$		$r_{22}^1 + r_{22}^1 \cdot (r_{22}^1)^* \cdot r_{22}^1$		$r_{22}^2 + r_{23}^2 \cdot (r_{33}^2)^* \cdot r_{22}^2$
$r_{23}$		$r_{23}^0 + r_{21}^0 \cdot (r_{11}^0)^* \cdot r_{13}^0$		$r_{23}^1 + r_{22}^1 \cdot (r_{22}^1)^* \cdot r_{23}^1$		$r_{23}^2 + r_{23}^2 \cdot (r_{33}^2)^* \cdot r_{23}^2$
$r_{31}$		$r_{31}^0 + r_{31}^0 \cdot (r_{11}^0)^* \cdot r_{11}^0$		$r_{31}^1 + r_{32}^1 \cdot (r_{22}^1)^* \cdot r_{31}^1$		$r_{31}^2 + r_{33}^2 \cdot (r_{33}^2)^* \cdot r_{31}^2$
$r_{32}$		$r_{32}^0 + r_{31}^0 \cdot (r_{11}^0)^* \cdot r_{12}^0$		$r_{32}^1 + r_{32}^1 \cdot (r_{22}^1)^* \cdot r_{32}^1$		$r_{32}^2 + r_{33}^2 \cdot (r_{33}^2)^* \cdot r_{32}^2$
$r_{33}$		$r_{33}^0 + r_{31}^0 \cdot (r_{11}^0)^* \cdot r_{13}^0$		$r_{33}^1 + r_{32}^1 \cdot (r_{22}^1)^* \cdot r_{33}^1$		$r_{33}^2 + r_{33}^2 \cdot (r_{33}^2)^* \cdot r_{33}^2$

Dans notre exemple, on obtient la table complétée suivante :

$r_{ij}$	$k = 0$	$k = 1$	$k = 2$
$r_{11}$	$\emptyset$	$\emptyset$	$\emptyset$
$r_{12}$	$b$	$b$	$b + b \cdot b^* \cdot b$
$r_{13}$	$b$	$b$	$b + b \cdot b^* \cdot a$
$r_{21}$	$\emptyset$	$\emptyset$	$\emptyset$
$r_{22}$	$b$	$b$	$b + b \cdot b^* \cdot b$
$r_{23}$	$a$	$a$	$a + b \cdot b^* \cdot a$
$r_{31}$	$a$	$a$	$a$
$r_{32}$	$\emptyset$	$a \cdot b$	$a \cdot b + a \cdot b \cdot b^* \cdot b$
$r_{33}$	$a$	$a + a \cdot b$	$a + a \cdot b + a \cdot b \cdot b^* \cdot a$

$$\begin{aligned} \text{Soit } r = & \varepsilon + (b + b \cdot b^* \cdot a) \cdot (a + a \cdot b + a \cdot b \cdot b^* \cdot a)^* \cdot a \\ & + (a + (a + a \cdot b + a \cdot b \cdot b^* \cdot a) \cdot (a + a \cdot b + a \cdot b \cdot b^* \cdot a)^* \cdot a) \end{aligned}$$